

数据库系统

第1章 数据管理技术引论



0.1 计算机信息管理系统定义

■“Information systems (IS) is the study of complementary networks of hardware and software that people and organizations use to collect, filter, process, create, and distribute data.”——数据处理

■“Information systems are combinations of hardware, software, and telecommunications networks that people build and use to collect, create, and distribute useful data, typically in organizational settings.”——体系结构

■“Information systems are interrelated components working together to collect, process, store, and disseminate information to support decision making, coordination, control, analysis, and visualization in an organization.”——实际应用



0.1 计算机信息管理系统定义

3

完整的计算机信息系统由五个部分组成：

Hardware, Software, Data, User, and Process.

Hardware, Software, Data涉及计算机信息系统构建的技术部分，使系统运行更可靠有效

User, Process涉及计算机信息系统构建的应用背景和业务流程部分，使系统功能满足用户需求




0.2 数据和信息

- **数据**：反映客观事物的性质、属性及其相互关系的一种表示形式，它可以是字母、数字、甚至图像、声音等各种可以鉴别的符号。
 - 数据项可以按使用目的组织成数据结构。
 - 数据经过加工和处理，能够为人所用时，数据成为了信息。
- **信息**：泛指包含于消息、情报、指令、数据、图像、信号等形式之中的新的知识和内容。
 - 信息是经过**加工**后的数据，具有特定的意义，它对接收者的行为能产生影响，对决策具有价值。



0.3 信息的特性

5



- 信息的**准确性**、**可靠性**和**时效性**是度量信息价值的基本要素。



0.4 信息系统的组成

- 信息系统可以分为**技术组成**和**社会组成**。
- 信息系统的**技术组成**指系统工作的基本软、硬件环境，主要包括：
计算机、网络、以及办公自动化的硬件设备；系统软件及基础软件；数据库管理系统及数据库；模型库和算法库；信息系统应用软件。
- 信息系统的**社会组成**指信息系统开发和使用管理过程中的组织或人员，主要包括：
组织；最终用户；系统开发者；系统管理者。

由于信息系统是一个复杂的人机系统，系统设计者不应该期望机器全权处理一切问题，而是要合理地分析什么工作交给机器做，什么工作由人做比较合适，人和机器如何联系等等，建设人与机器的和谐应用环境。

0.5 管理信息系统

- 管理信息系统 (Management Information System) 简称 **MIS**，是1961年在美国由J. D. Gallagher首先提出的，并确定其以计算机为主体、信息处理为中心的综合性的系统。
- 管理信息系统**综合**了管理科学、信息科学、计算机科学、统计学、运筹学等许多学科的概念和方法。
- MIS系统是由**计算机技术**、**网络通信技术**、**信息处理技术**、**管理科学**和**人**组成的一个综合系统，它能提供信息，以支持一个组织机构的运行、管理和决策功能。



0.1 MIS系统的应用类型

- (1) 国家经济信息系统
- (2) 企业管理信息系统
- (3) 事务型管理信息系统
- (4) 行政机关办公型管理信息系统
- (5) 专业型管理信息系统
- (6) 综合型信息系统




0.1 传统MIS的缺陷

- 封闭式单项单系统，不同的系统无法交流；
- 用户界面风格不一，使用繁杂，不利于推广使用；
- 维护性差，过多地依赖于开发者的维护和修改；
- 无法包容已有系统，造成重复投资；
- 软件开发周期长，往往是基于某一种操作系统，采用特定的编程语言进行底层开发；
- 系统生命周期短，移植困难，升级麻烦；
- 系统质量难以保证。



1.1 从图灵机看数据

10



- 图灵机由一条纸带、一个读写头（处理盒）和一个程序组成
- 纸带就代表了存储设备以及上面的数据
- 读写头代表处理用的硬件设备
- 程序代表计算机中的操作指令

1.2 什么是数据？

■ 数据(Data)

- 是可以存储在计算机中的基本对象

■ 数据的种类

- 数字、文本、图形、图像、音频、视频等

■ 数据的定义

- 描述事物的符号记录，可以是单个值，也可以是值的组合

■ 数据的特点

- 数据与其语义是不可分的



■ 学生档案中的学生记录

(李明, 男, 1990, 江苏, 计算机系, 2009)

■ 数据的形式不能完全表达其内容

■ 数据的解释

■ **语义**: 学生姓名, 性别, 出生年月, 籍贯, 所在系别, 入学时间

■ **解释**: 李明是个学生, 男, 1990年出生, 江苏人, 2009年考入计算机系

■ 解释数据的数据——称为“元数据”



- **数据采集：**指产生新的数据或选取现有数据的过程。
- **数据管理：**指以数字格式对数据进行物理存储和高效管理。
- **数据处理：**指针对数据进行的一系列活动的组合。
- **数据传输与交换：**指数据的流动和交互过程。
- **数据销毁：**指使数据彻底丢失且无法恢复的过程。



1.2 什么是数据？

- 什么样的数据可以分析？
 - 客观事物的度量数据——特征
- 人工编号是否可以用于分析？
 - 一般只具有指代作用，不含语义信息
 - 可用于数据匹配，通常不用于分析
 - ONE-HOT编码常用于自然语言处理，主要用于词的**组合关系**和**序列关系**的分析
- 组合编号是不是数据？
 - 可以看作多种特征的**组合**



1.3 数据的作用

- 从大量数据中快速查询与检索
 - 检索历史病例
 - 查询病史信息
- 从大量数据中分析潜在线索与规律
 - 长沙地区口腔癌发病规律
 - 皮肤炎继发间质性肺炎致死规律
- 用于构建计算模型和工具，辅助工作
 - 胃腺癌病理诊断辅助模型
 - 糖尿病足创面辅助评估模型



1.3 数据的作用

- 从大量数据中快速查询与检索
 - 检索单位人员信息
 - 查询下发文件信息
- 从大量数据中分析潜在线索与规律
 - 各单位战斗力综合评估
 - 挖掘网络潜在高价值虚拟目标
- 用于构建计算模型和工具，辅助工作
 - 开源文本数据智能分析模型
 - 情报文本智能编排纠错模型



1.4 用数据的视角看信息系统

- 信息系统开发过程中的**功能视角**、**数据视角**和**程序视角**
- 功能视角：从应用的角度分析系统包含的主要功能
- 数据视角：分析支持功能所需要的数据以及数据管理方式
- 程序视角：从数据到功能之间的映射过程

■ 教师：表


教师编号	姓名	性别	工作时间	政治面目	学历	职称	系别	电话号码
95010	张乐	女	1969年11月10日	党员	大学本科	教授	经济	(6597)6444
95011	赵希明	女	1983年1月25日	群众	研究生	讲师	经济	(6597)6451
95012	李小平	男	1963年5月19日	党员	研究生	教授	经济	(6597)6452
95013	李历宁	男	1989年10月29日	党员	大学本科	助教	经济	(6597)6453
96010	张爽	男	1958年7月8日	群众	大学本科	教授	经济	(6597)6454
96011	张进明	男	1992年1月26日	团员	大学本科	副教授	经济	(6597)6455
96012	邵林	女	1983年1月25日	群众	研究生	数学	数学	(6597)6444
96013	李燕	女	1969年6月25日	群众	大学本科	讲师	数学	(6597)6444
96014	苑平	男	1957年9月18日	党员	研究生	教授	数学	(6597)6445
96015	陈江川	男	1988年9月9日	党员	大学本科	讲师	数学	(6597)6446
96016	晋复	女	1963年5月19日	群众	研究生	副教授	数学	(6597)6447

程序



1.5 从图灵机看数据管理

18



- 读写数据过程中读写头移动的距离尽可能的少——**存储位置**
- 对数据的访问方式应尽可能简单——**逻辑结构**
- 不同的程序都可以访问——**独立性**
- 数据冗余尽可能少
- 数据可共享，方便检索
- 数据安全可靠

1.6 数据管理技术的产生与发展

■ 什么是数据管理

- 对数据进行分类、组织、编码、存储、检索和维护
- 目的是便于数据访问，提高数据处理和分析的效率

■ 数据管理技术的发展过程

- 人工管理阶段
- 文件系统阶段
- 数据库系统阶段
- 混合存储阶段



1) 人工管理阶段

- 40年代中期～50年代中期
- 产生的背景
 - 应用需求：科学计算
 - 硬件水平：无磁盘
 - 软件水平：无操作系统
 - 处理方式：批处理



1) 人工管理阶段


21

■ 特点:

- 数据不保存
- 应用程序管理数据
- 数据无共享、冗余度极大
- 数据不具有独立性，完全依赖于程序
- 数据无结构



应用程序与数据的对应关系(人工阶段)²²



- 只有程序的概念
- 没有文件的概念
- 没有专用的软件管理数据



2) 文件系统阶段

- 50年代中后期以来
- 产生的背景
 - 应用需求：科学计算、信息管理
 - 硬件水平：磁盘、磁鼓
 - 软件水平：有文件系统
 - 处理方式：联机实时处理、批处理



2) 文件系统阶段


24

■ 特点:

- 数据可长期保存
- 文件系统管理数据
- 文件内数据**存储有结构**，但**访问无结构**
- 数据的共享性差、冗余度大
- 数据的独立性差，数据**逻辑结构**改变必须修改**应用程序**




应用程序与数据的对应关系(文件阶段)²⁵



文件存储示意图

26

- 通过操作系统的**文件系统**，应用程序以对**文件**进行**读写操作**的形式访问数据（数据记录序列）
- 利用**文件名**和**相对地址**访问，而不用关心数据在介质层的存储细节



26



文件系统中数据的数据结构



- 不含有专门的元数据，数据的**结构和语义**靠应用程序**定义和解释**
- 文件之间**相互独立**，无法跨文件数据统一管理

例：要建立学生成绩管理系统，包含的数据分别对应三个文件。

- 学生（学号、姓名、性别、队别、年龄）
- 课程（课程号、课程名、学分）
- 成绩（学号、课程号、成绩）




- 文件系统只能用于表示同一文件内部数据的联系
- 无法直接描述跨文件数据之间的联系




文件系统中数据的独立性

29

1) 数据结构改变




2) 数据结构扩展



销售信息管理系统—基于文件系统的方式

30



3) 数据库阶段

31

■ 时期

- 60年代末以来

■ 产生的背景

- 应用背景：大规模数据管理
- 硬件背景：大容量磁盘
- 软件背景：有数据库管理系统
- 处理方式：联机实时处理、分布处理、批处理



读者

借书、还书、预订

图书
管理员

书库



各类信息

最终用户

应用程序


数据库管理系统
(DBMS)

基本数据库



应用程序与数据的对应关系(数据库)

33



数据库存储示意图

应用程序

- 通过**数据库管理系统**，应用程序以对**表格**进行**操作运算**的方式访问数据
- DBMS**将表格中的数据与文件存储对应，将**表格操作**转换成**文件操作**



学号	姓名	性别	年龄
990001	张红	男	19
990002	王力	男	20
990003	李丽	女	18
990004	刘齐	男	21
990005	张凤	女	22
990006	陈耳	女	17

数据库管理系统

文件

文件系统

介质上的数据


数据库中数据的结构

- 包含有元数据，DBMS可以完成对**数据结构的定义和数据语义的解释**
- 数据基于数据字典（元数据）进行**统一管理**
- 数据整体**结构化**
- 数据的共享性高、**冗余度低**
- 数据具有高度的**物理独立性**
- 数据具有一定的**逻辑独立性**
- 数据的安全性好、可靠性高



销售信息管理问题—数据库解决方案

36



- **Oracle**
- **Microsoft SQL Server**
- **MySQL**
- **IBM DB2**
- **Microsoft Access**
- **Microsoft FoxPro**
- **Microsoft Visual FoxPro**
- **Sybase**
- **Informix**



- 依托文件系统，以记录为单位管理数据，维持着一个复杂的数据字典，特别是索引系统，不利于PB级规模的数据管理
- 数据管理高度结构化，而结构化过程意味着巨大的预处理开销
- 数据存储节点数量有限，不利于存储弹性可扩展



■ 1) MIS系统的普及与应用

- 利用计算机技术加强企业信息管理，加工处理数据并编制成各种信息资料提供给管理者

■ 2) 数据仓库与数据挖掘

- 数据仓库是对原有分散的数据库数据抽取、清理、加工、汇总，以获得整个企业的一致全局信息，用于分析
- 数据挖掘是从大量数据中揭示出隐含的、先前未知的并有潜在价值的信息的过程



■ 3) 数据集成与数据空间(DataSpace)

- 数据集成是把不同来源、格式、特点性质的数据在逻辑上或物理上有机地集中，从而为企业提供全面的数据共享

■ 4) 云计算与GFS/MapReduce/BigTable

- 云计算是分布式计算的一种，它将巨大的数据计算处理作业分解成无数个小任务，通过集群系统进行处理，再将得到的结果收集并返回给用户



Thanks!

